ATA
互通 合作 成长

云栖社区
CODING LIFE

阿里巴巴云化架构创新之路

个人介绍

- 丁宇，阿里花名叔同
- 天猫双11技术大队长，资深技术专家
- 2010年加入淘宝网、8次参与双11作战
- 阿里高可用架构负责人、双11稳定性负责人
- 阿里容器、调度、集群管理、运维技术负责人
- 推动和参与了双11几代技术架构的演进和升级

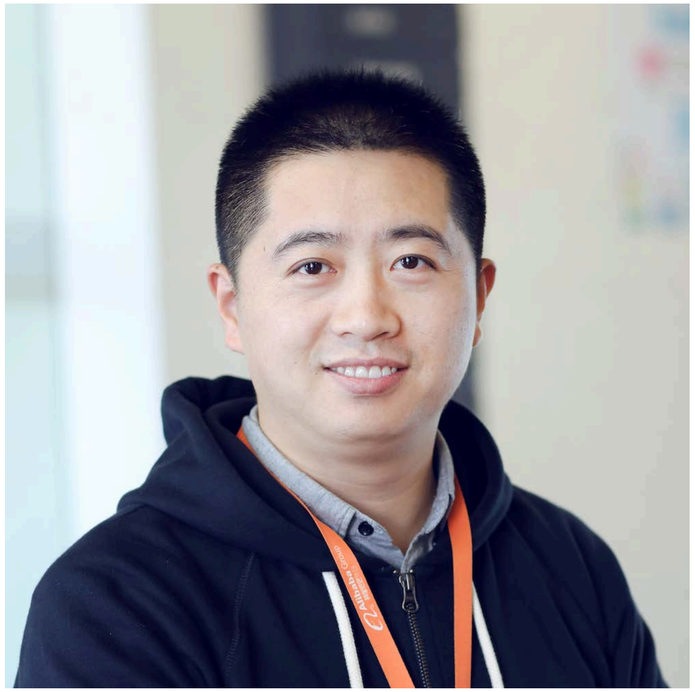

议程

01 双11的技术挑战与突破

02 云化架构演进的背景

03 统一调度和混部的挑战

04 Pouch容器和容器化的进展

05 云化架构和双11的未来技术路线

双11的技术挑战

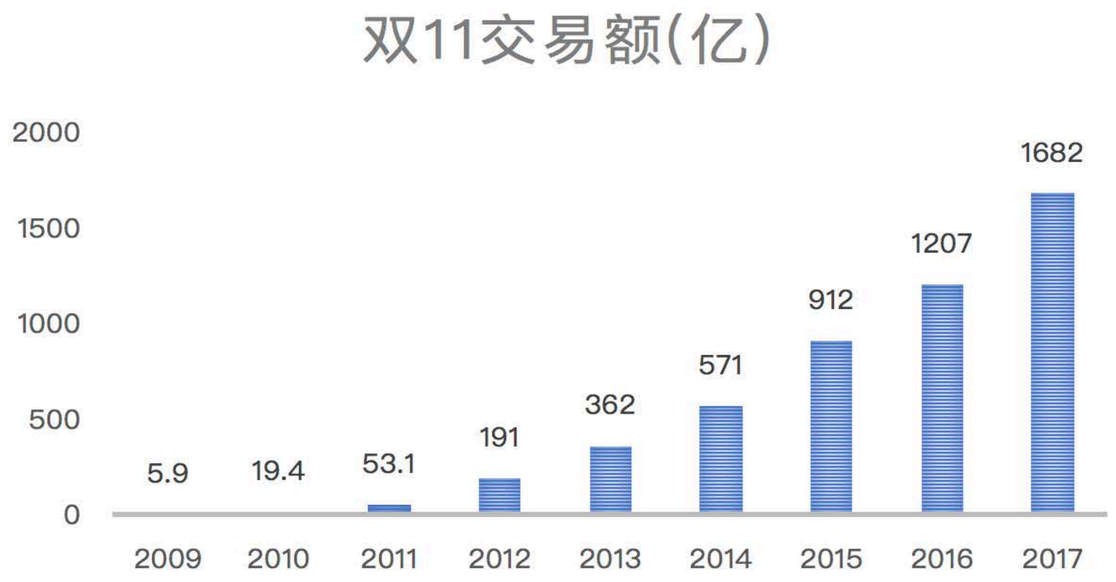

- 双11的技术挑战，互联网级的规模，企业级的复杂度，金融级的稳定性，数十倍的业务峰值
- 9次双11交易额增长280倍，交易峰值增长800多倍，系统复杂度和大促支撑难度以指数级攀升
- 双11峰值的本质是用有限成本去最大化的提升用户体验和集群吞吐能力，用合理的代价解决峰值
- 发挥规模效应，持续降低单笔交易成本以提升峰值能力，为用户提供丝般顺滑的浏览和购物体验

双11的技术突破

突破与演进方向

扩展性问题

- 分布式架构
- 异地多活

稳定性问题

- 限流降级
- 全链路压测

新的技术挑战

- 成本、效率

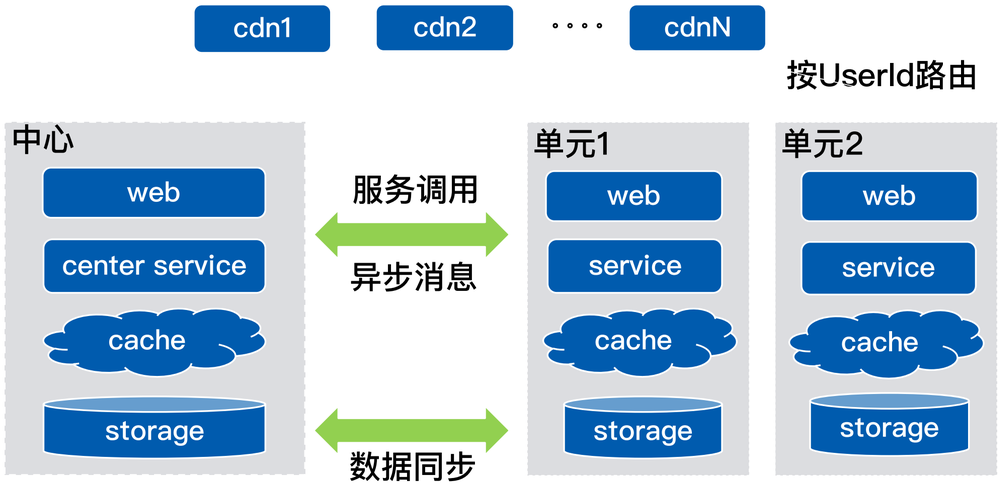

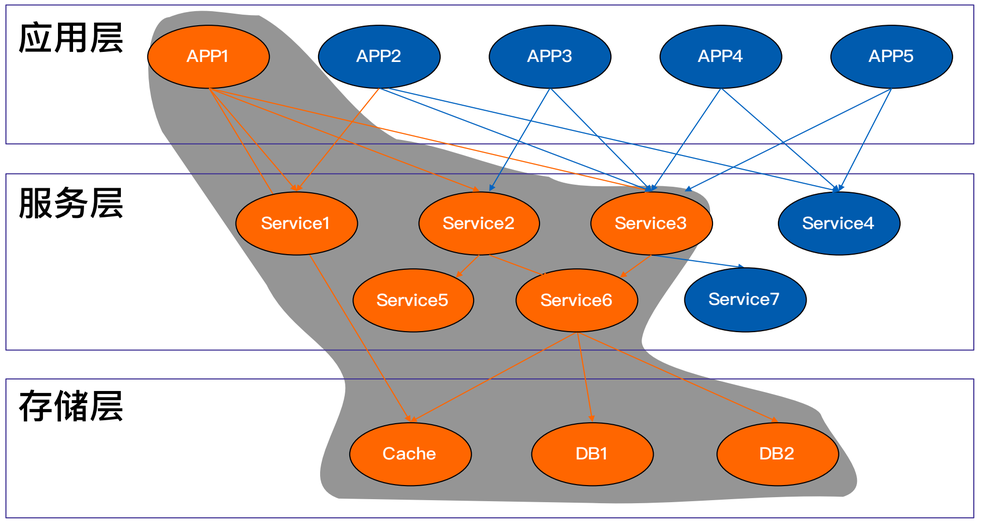

云化架构演进背景

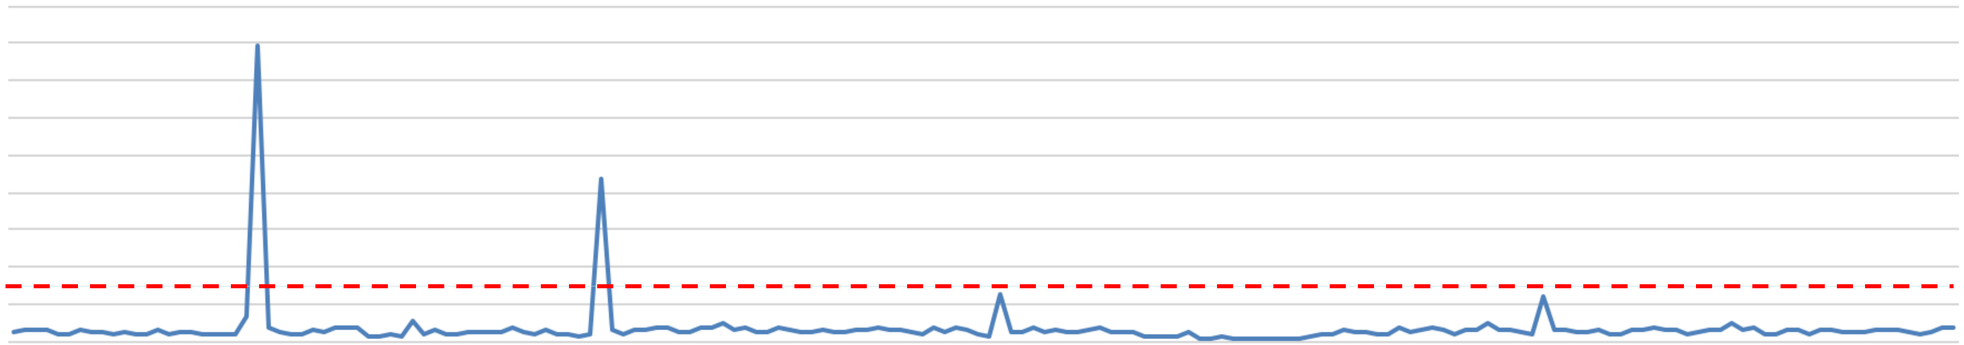

- 双11只有一天，过后资源利用率不高， 隔年会形成较长时间的低效运行
- 资源整体弹性能力不足，运维体系差异大，各版块无法平滑复用
- 每个版块有不同的Buffer池，在线率、分配率、利用率无法统一
- 通过云化架构提升整体技术效率，提高全局资源弹性复用能力
- 拉通技术体系，降低大促和日常整体成本，双11单笔交易成本减半

垂直化运维体系

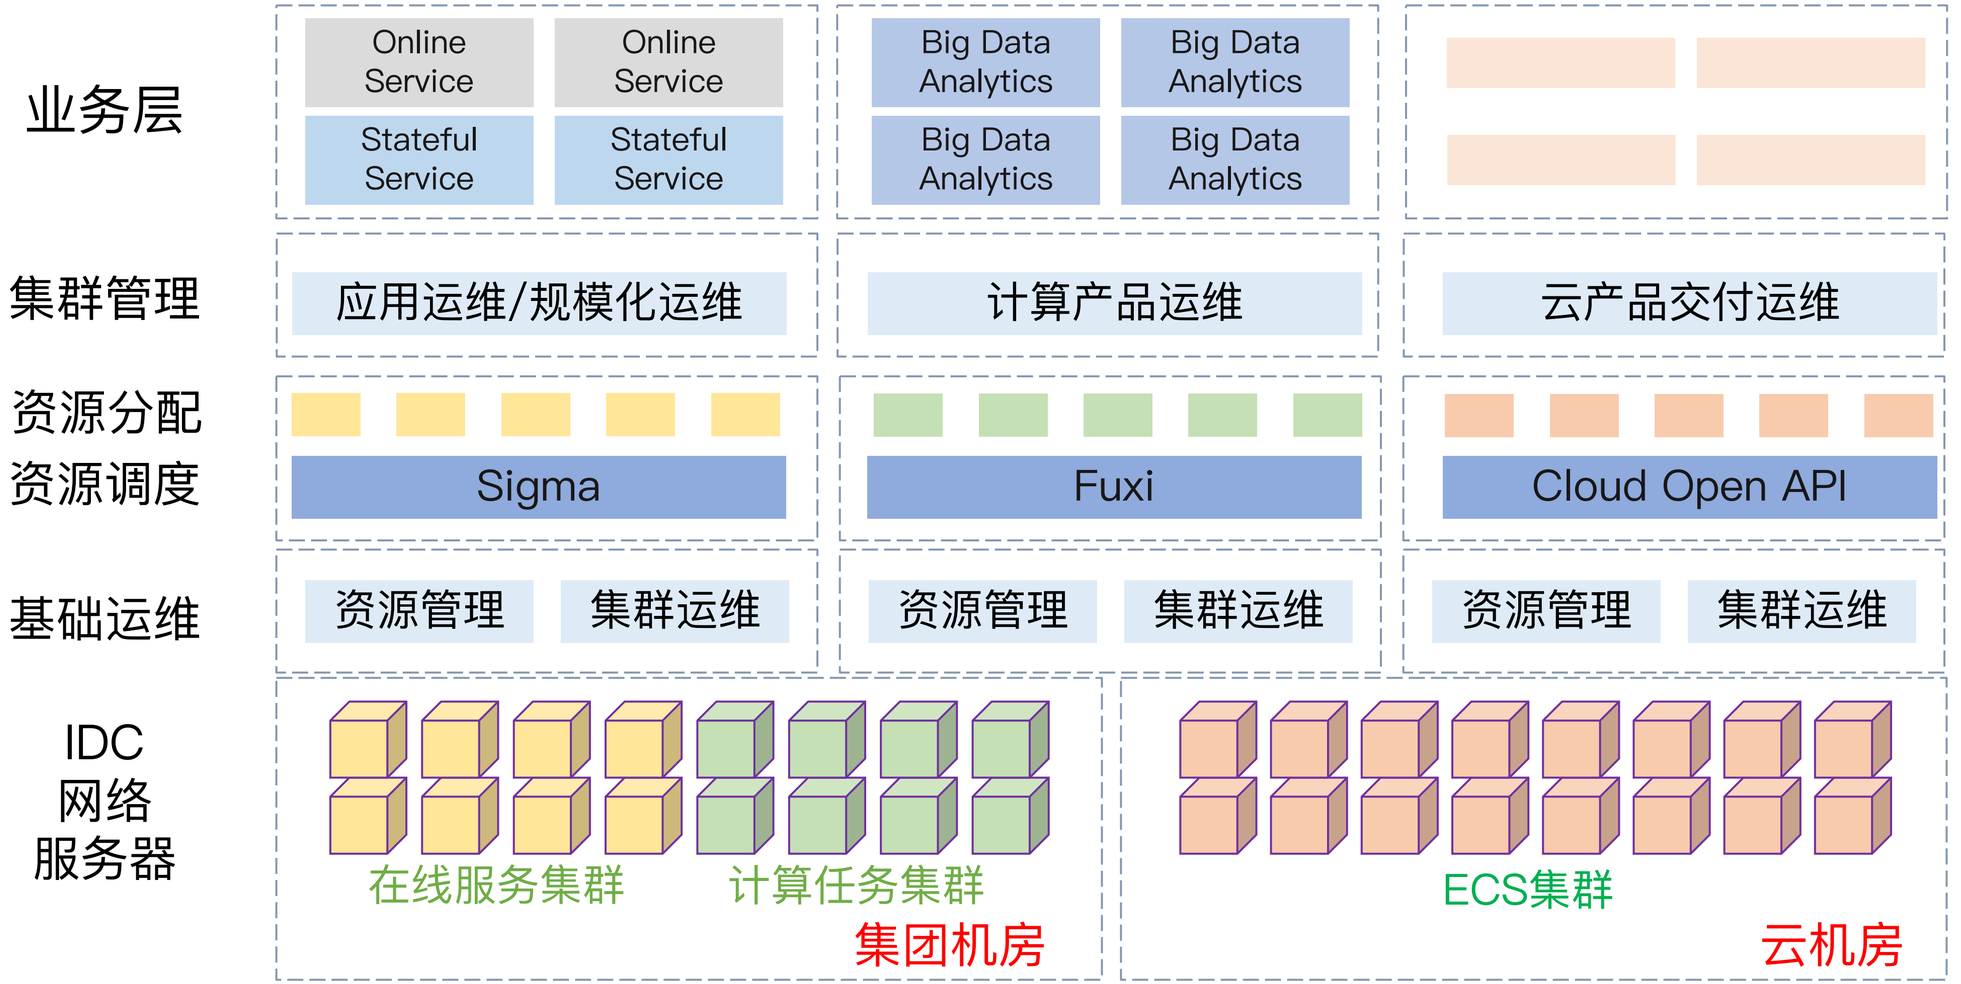

- 技术全面云化，逐层重构升级，弹性复用资源，全局统一调度，在线服务和计算任务混部
- 统一运维部署、资源分配的标准，提高调度效率，容量自动交付，全面容器化
- 充分发挥云计算的弹性能力，减少自采基础设施投入，混合云弹性架构，一键建站

集群管理和调度系统Sigma

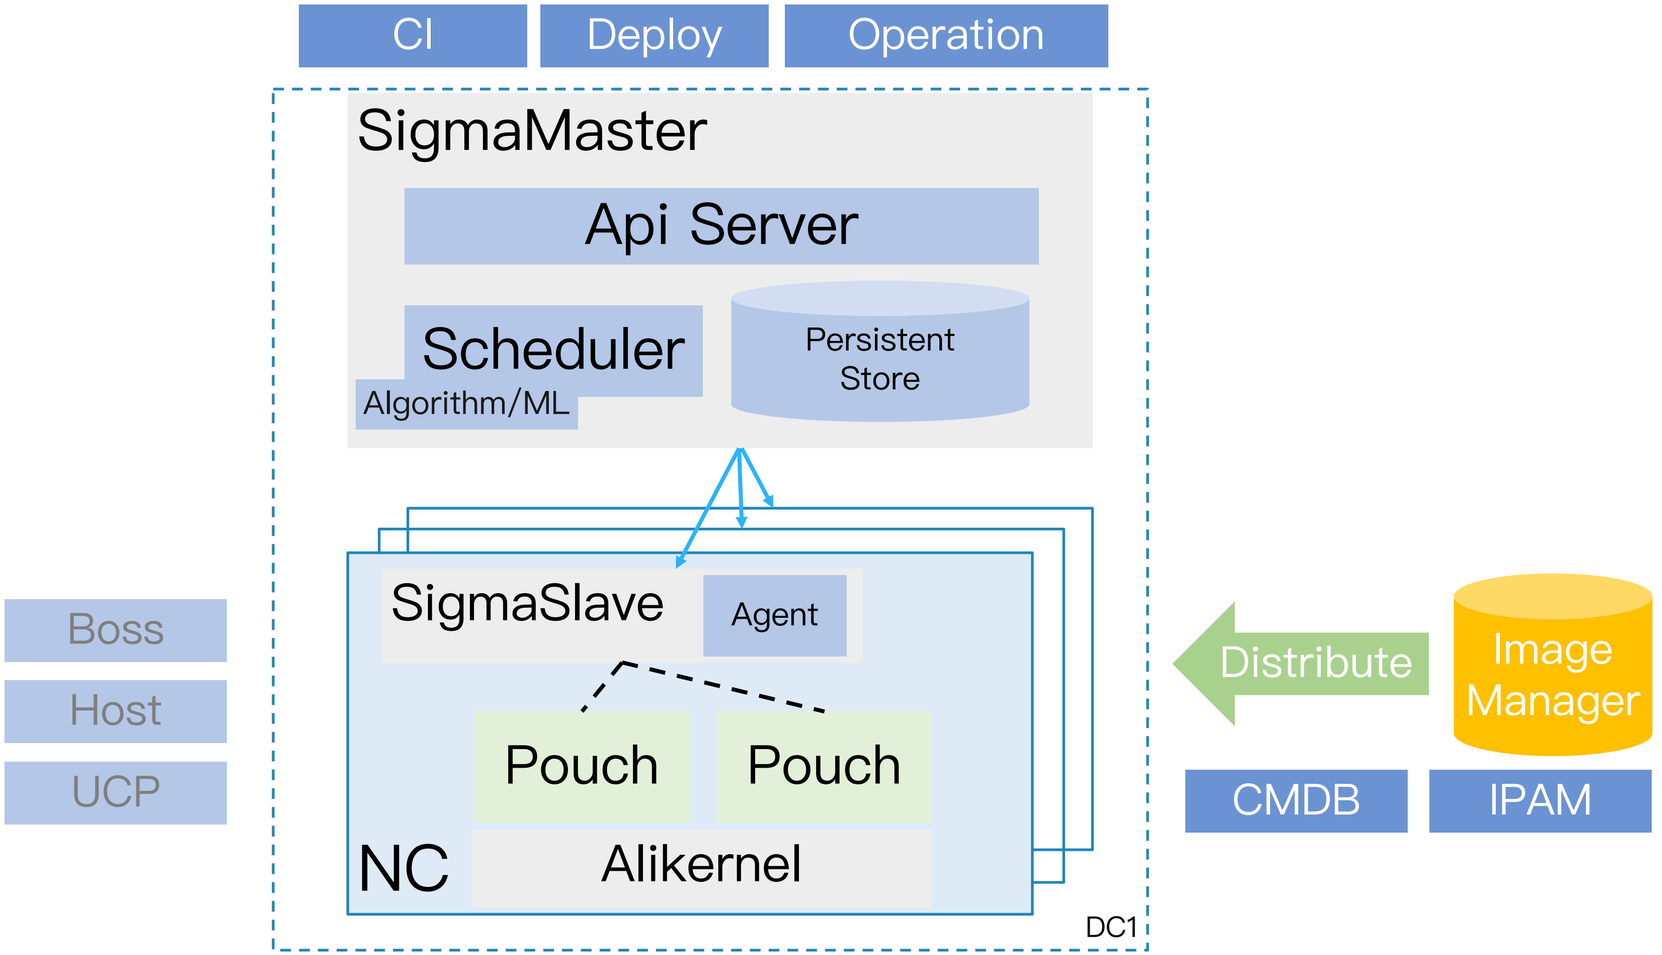

- 以调度为中心的集群管理体系，始于2011年
- 面向终态的架构设计；三层大脑合作联动管理
- Go语言重构，17年兼容Kubernetes API，和开源社区共同发展

调度现状

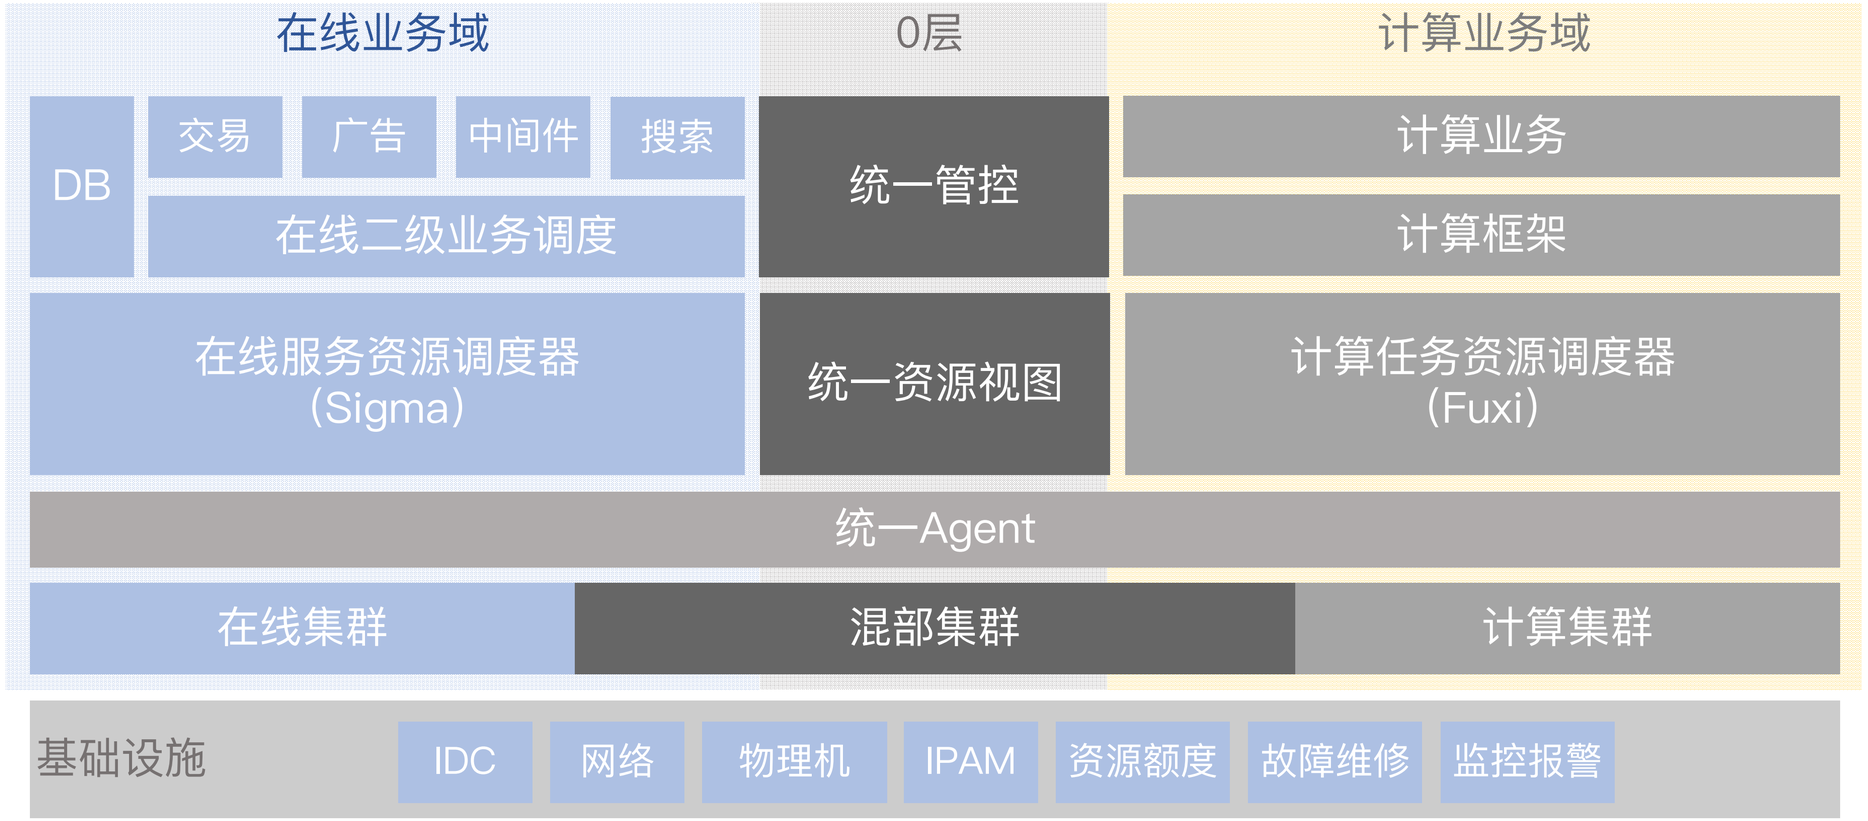

- 合并资源池，提升在线率、分配率去Buffer，空间维度优化
- 弹性分时复用，时间维度优化，共节省超过5%的服务器资源
- 发挥了统一调度、集中管理的优势，释放规模效益下的红利

Sigma与Fuxi混部架构

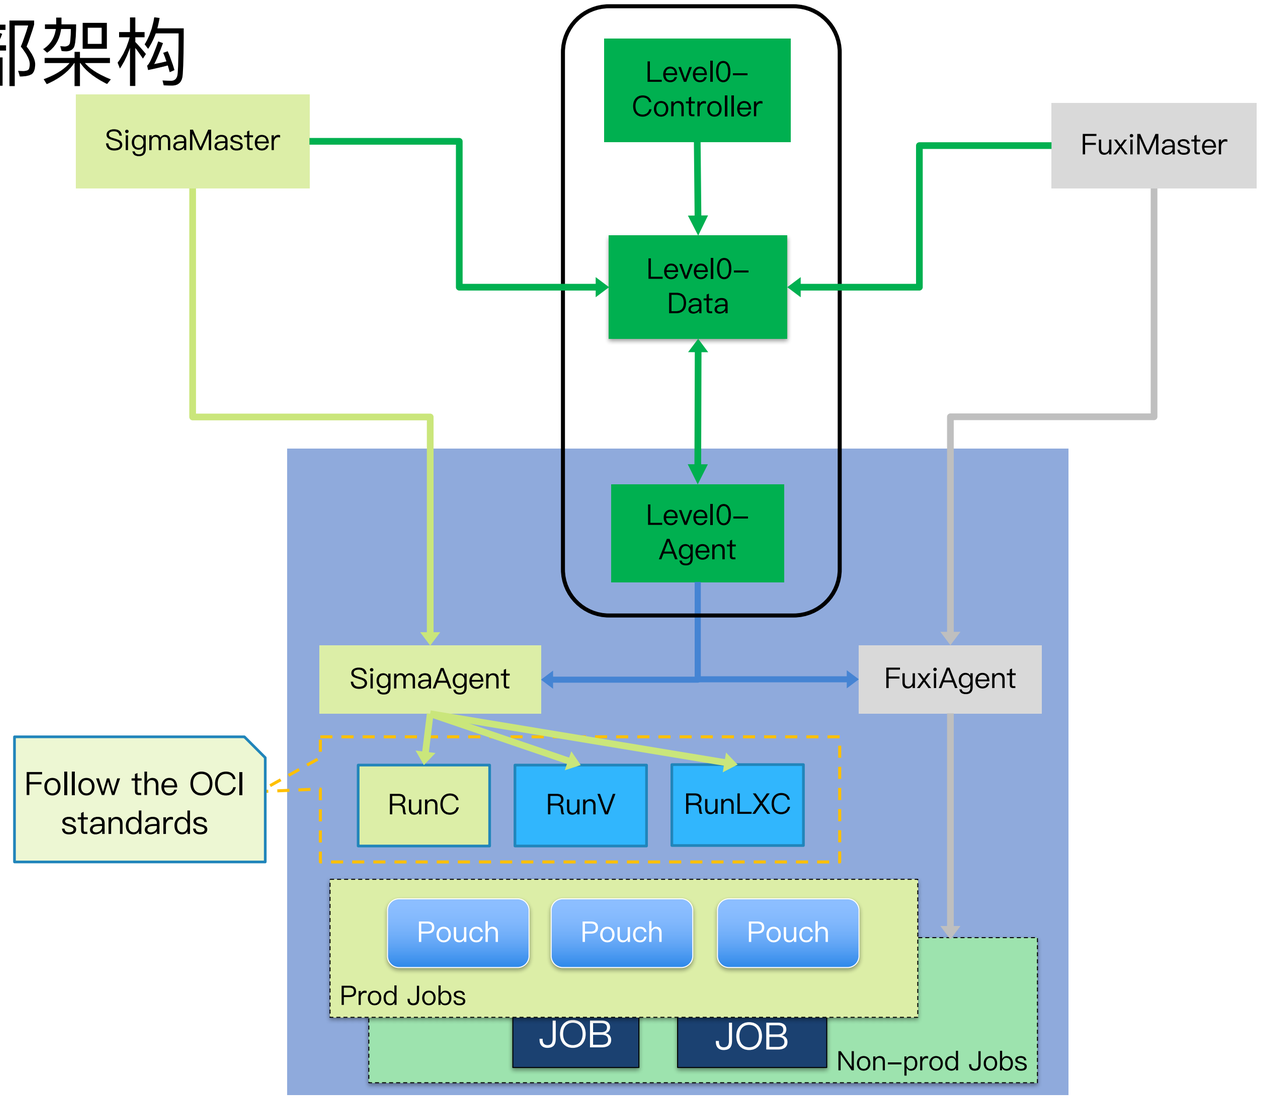

- 始于2014年，已在阿里内部大规模部署
- 通过Sigma和Fuxi完成在线服务、计算任务各自的调度，计算共享超卖
- 在线服务长生命周期/定制化规则策略复杂/时延敏感；计算任务短生命周期/大并发高吞吐

混布关键技术

- 内核资源隔离
  - CPU HT资源隔离：Noise Clean内核特性，解决在、离线超线程资源争抢问题
  - CPU 调度隔离：CFS基础上增加Task Preempt特性，提高在线任务调度优先级
  - CPU 缓存隔离：CAT，在、离线三级缓存(LLC)通道隔离(Broadwell及以上)
  - 内存隔离：CGroup隔离/OOM优先级；Bandwidth Control减少离线配额实现带宽隔离
  - 内存弹性：在线闲置时离线突破memcg limit；在线需要内存时离线及时释放
  - 网络QoS隔离：管控打标为金牌；在线打标为银牌；离线打标为铜牌，分级保障带宽

混布关键技术

- 在线集群管理
  - 应用画像，装箱调度
  - 亲和互斥、任务优先级
  - 稳定性优先、利用率优先
  - 应用自动伸缩、分时复用
  - 整站快速扩缩、弹性内存
- 计算任务调度+ODPS
  - 弹性内存分时复用
  - 动态内存超卖
  - 无损降级、有损降级

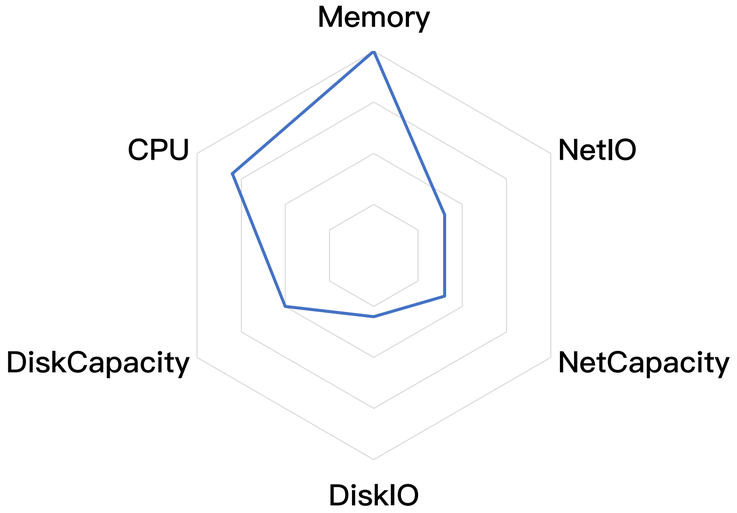

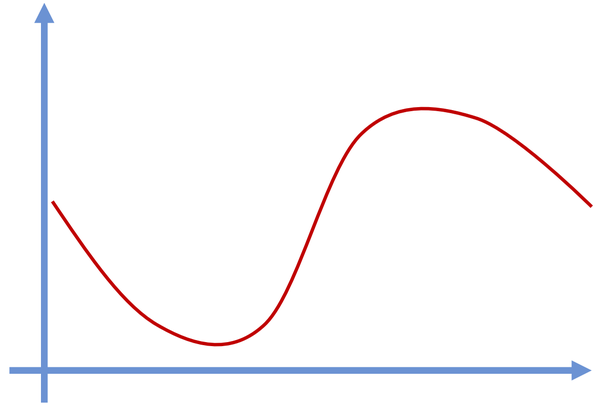

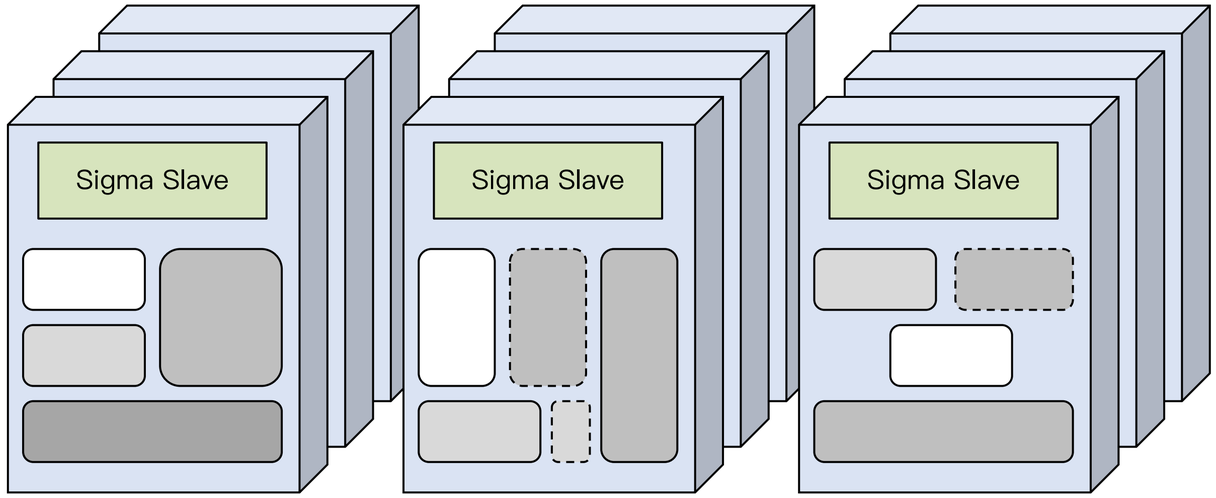

混合部署–引入计算任务提升日常资源效率

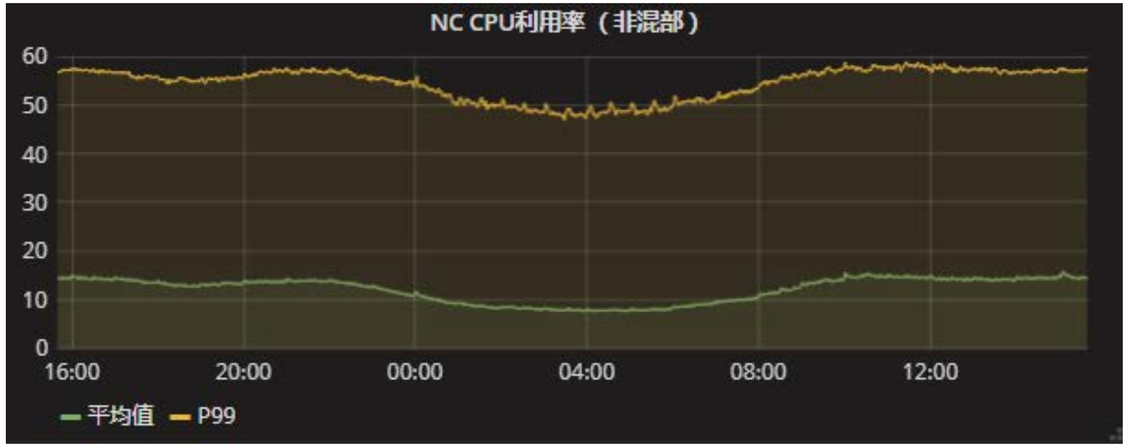

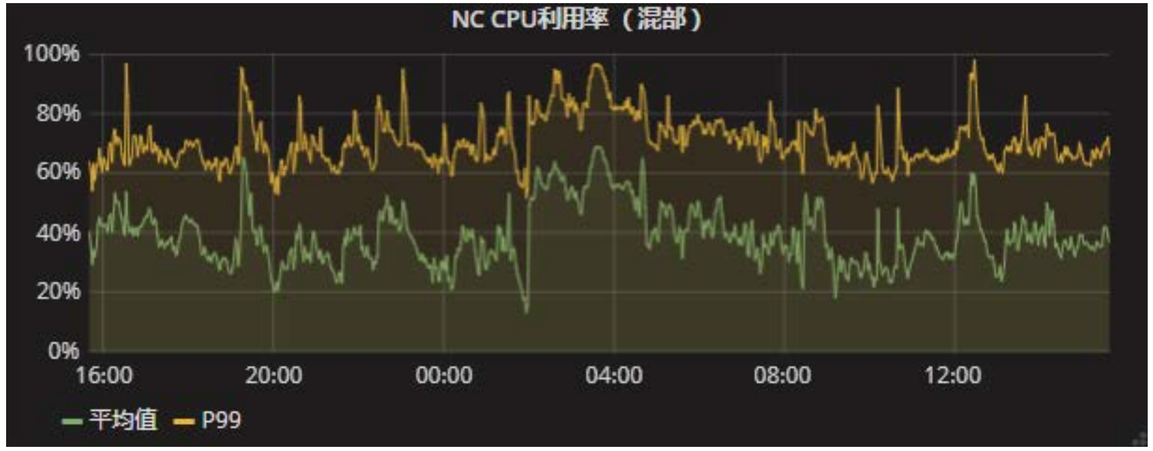

- CPU平均利用率10% –> 40%，延迟敏感类应用RT影响<5%
- 混部集群规模数千台，经过交易核心链路双11大促验证
- 为日常节省超过30%的服务器，明年会扩大10倍部署规模

混合部署-分时复用进一步提升资源效率

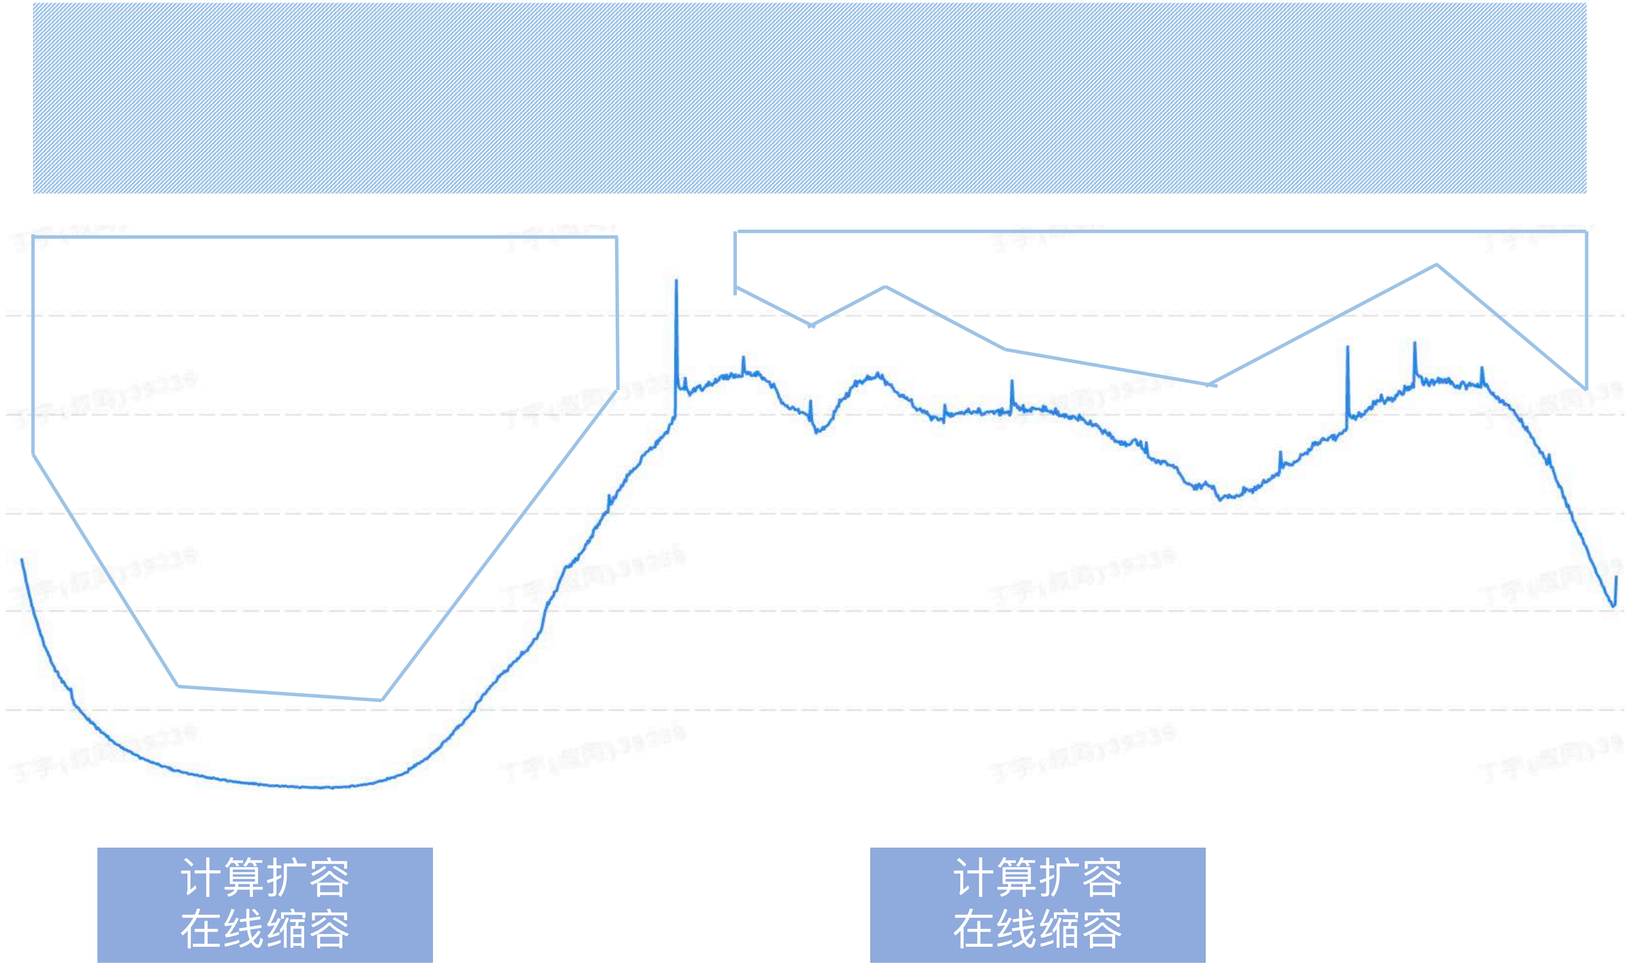

- 时间空间维度优化
- 结合弹性分时复用，平均CPU利用率提升至60%以上

混合部署–降低大促成本

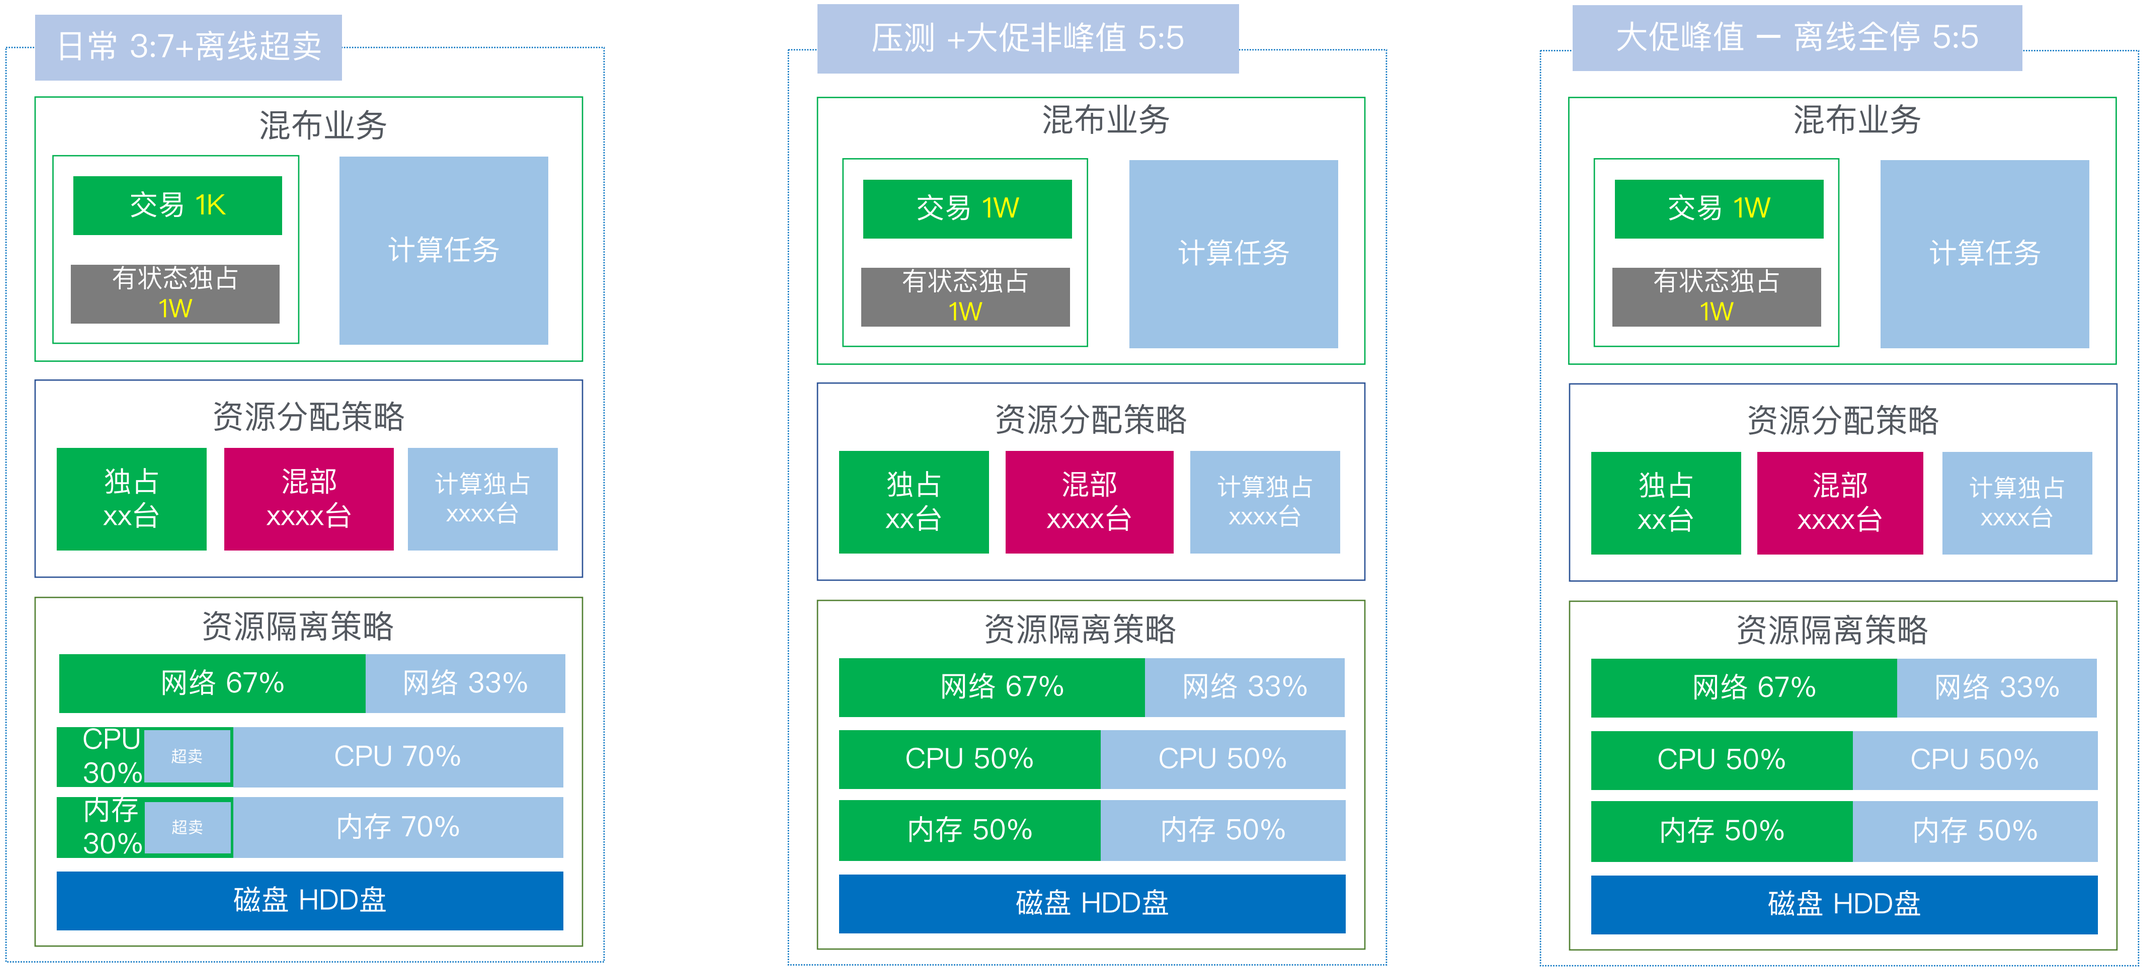

- 通过部分计算任务短时间降级，空闲资源支持双11交易峰值
- 1小时快速拉起完整站点，大幅降低了双11单笔交易成本

Pouch简介

- 本意育儿袋，隐喻贴身呵护应用
- 始于2011年，基于LXC
- 阿里内部容器技术产品，并于当年上线
- 2015年初开始吸收Docker镜像功能
- 容器结合阿里内核，大幅提高隔离性
- 百万级规模部署于阿里集团内部

Pouch发展路线

- 容器的要素--阿里内部运维和应用视角
  - 有独立IP
  - 能够ssh登陆
  - 独立的的文件系统
  - 资源隔离—使用量和可见性

- 手工Hack实现容器要素
  - 虚拟网卡，网桥
  - sshd
  - Chroot (pivot_root)
  - CGroup，Namespace

- 引入LXC（Linux Container）
- 内核可见性隔离Patch
- 内核磁盘空间配额Patch

阿里容器技术T4

引入Docker标准

Pouch定位

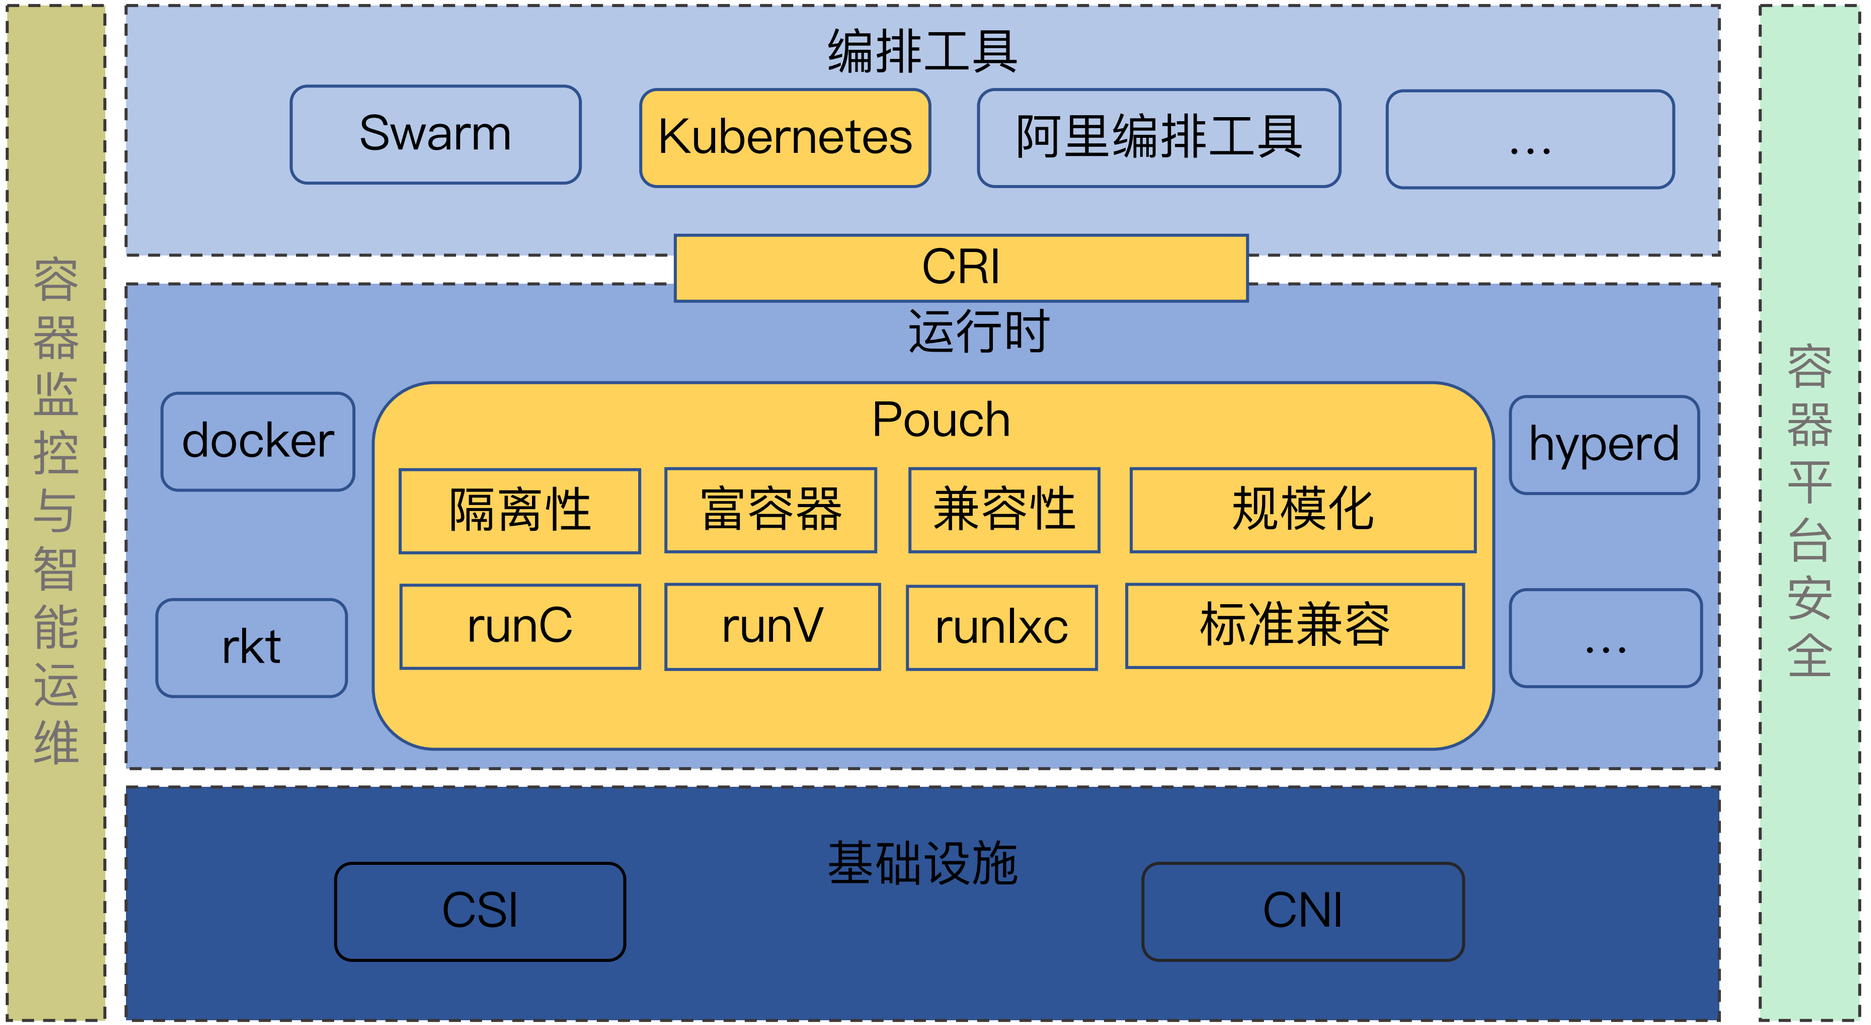
容器监控与智能运维
编排工具
Swarm
Kubernetes
阿里编排工具
…
CRI
运行时
docker
Pouch
hyperd
隔离性
富容器
兼容性
规模化
rkt
runC
runV
runlxc
标准兼容
…
基础设施
CSI
CNI
容器平台安全

Pouch架构

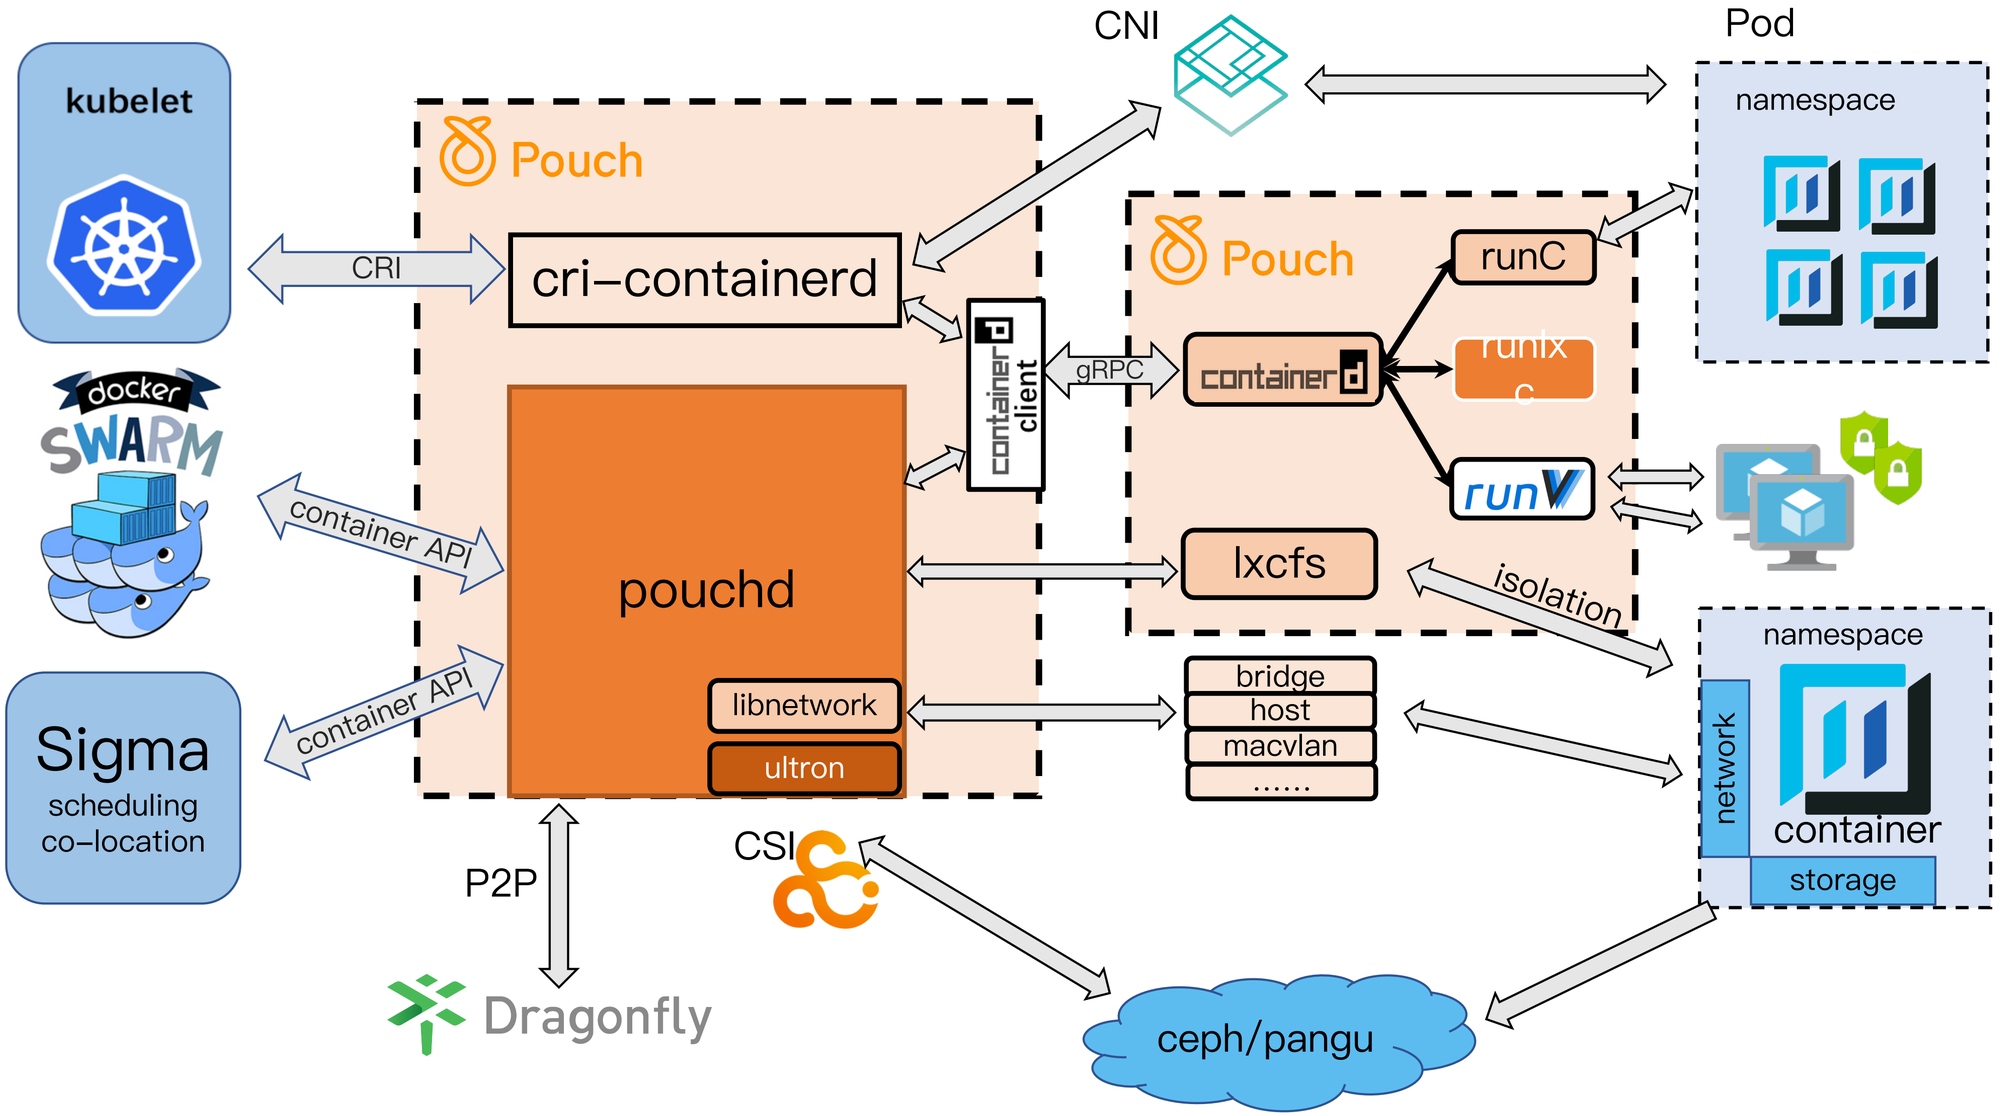
kubelet
docker
SWARM
Sigma
scheduling
co-location
CRI
container API
container API
Pouch
cri-containerd
pouchd
libnetwork
ultron
container client
gRPC
P2P
Dragonfly
CSI
CNI
Pod
namespace
Pouch
runC
runx
runV
container
lxcfs
isolation
bridge
host
macvlan
.....
namespace
network
container
storage
ceph/pangu

Pouch化进展

规模：

- 覆盖集团大部分BU
- 2017年双11百万级容器
- 在线业务100%容器化
- 计算任务开始容器化
- 拉平异构平台的运维成本

覆盖场景：

- 运行模式
- 多种编程语言
- DevOps体系

覆盖业务：

- 蚂蚁&交易&中间件
- B2B/CBU/ICBU/1688/村淘
- 合一集团（优酷）
- 菜鸟&高德&UC（接入中）
- 集团测试环境
- 广告（阿里妈妈）
- 阿里云专有云输出
- ……

Pouch开源计划

2017.10.10
合作伙伴共同孵化
外部开发者邀请内测

2017.11.19
正式开源
与生态共建Pouch

2018.03.01
发布第一个
大版本

https://github.com/alibaba/pouch

- 推动容器领域发展和标准成熟，给业界提供差异化有竞争力的选择
- 方便传统IT企业利旧，同样享受容器化带来的运维层优势
- 方便新IT企业享受规模化、稳定性和多标准兼容的优势

存储计算分离

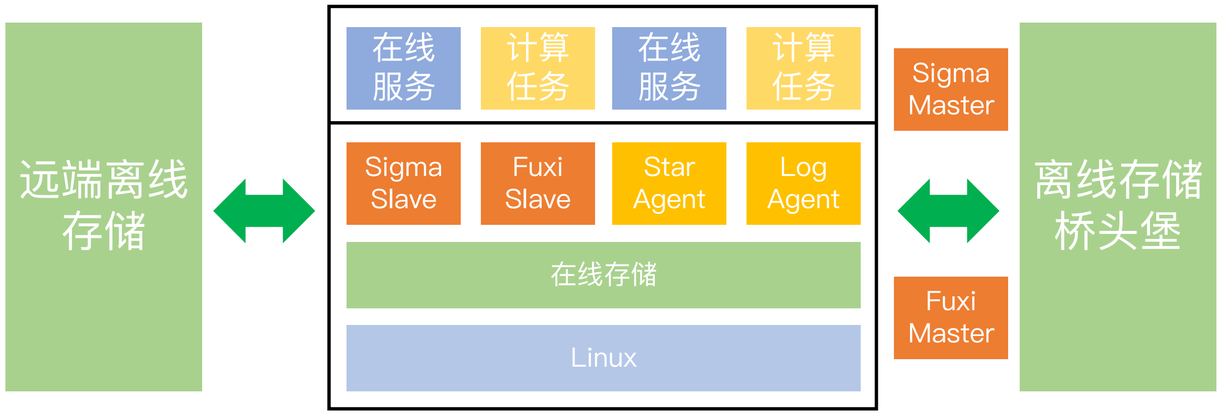

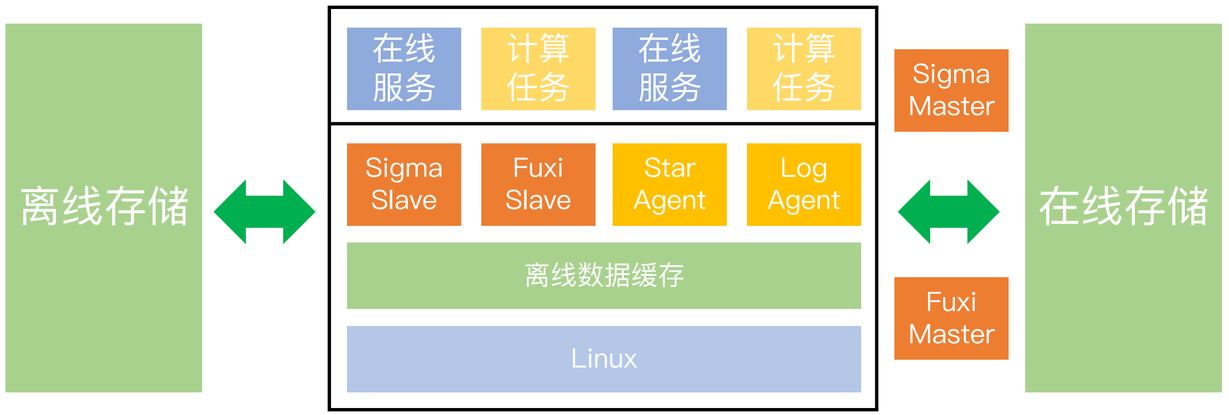

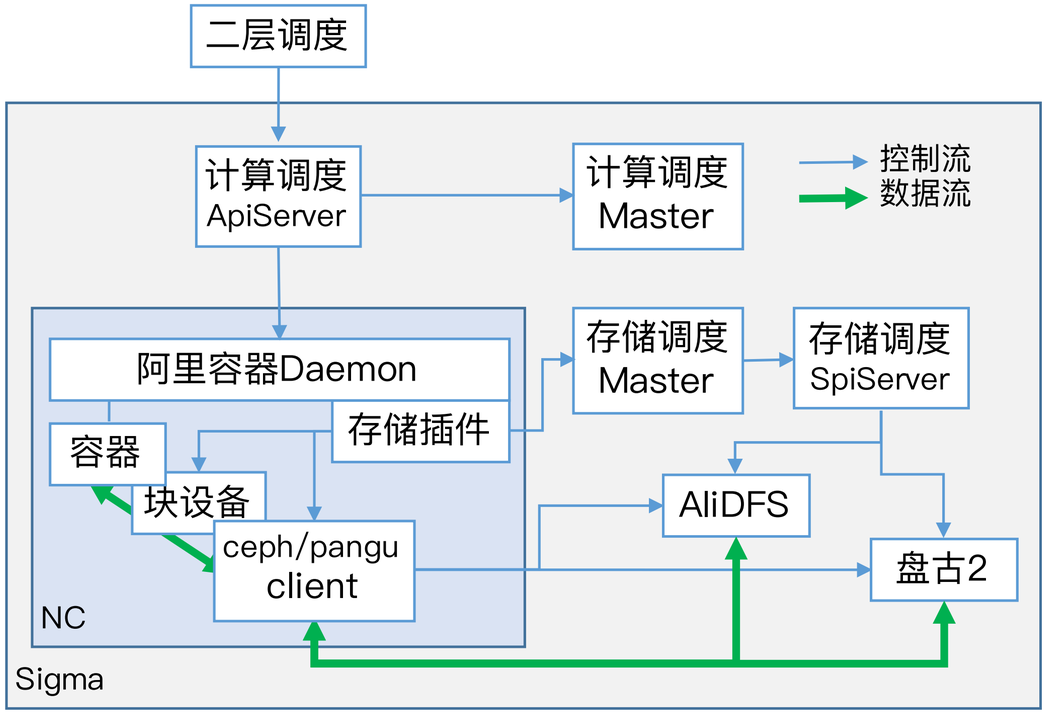

- 不受网络长传带宽限制
- 大集群减少跨网络核心对穿流量
- 有状态服务的存储计算分离
- 网络架构升级、25G、overlay

混合云弹性架构

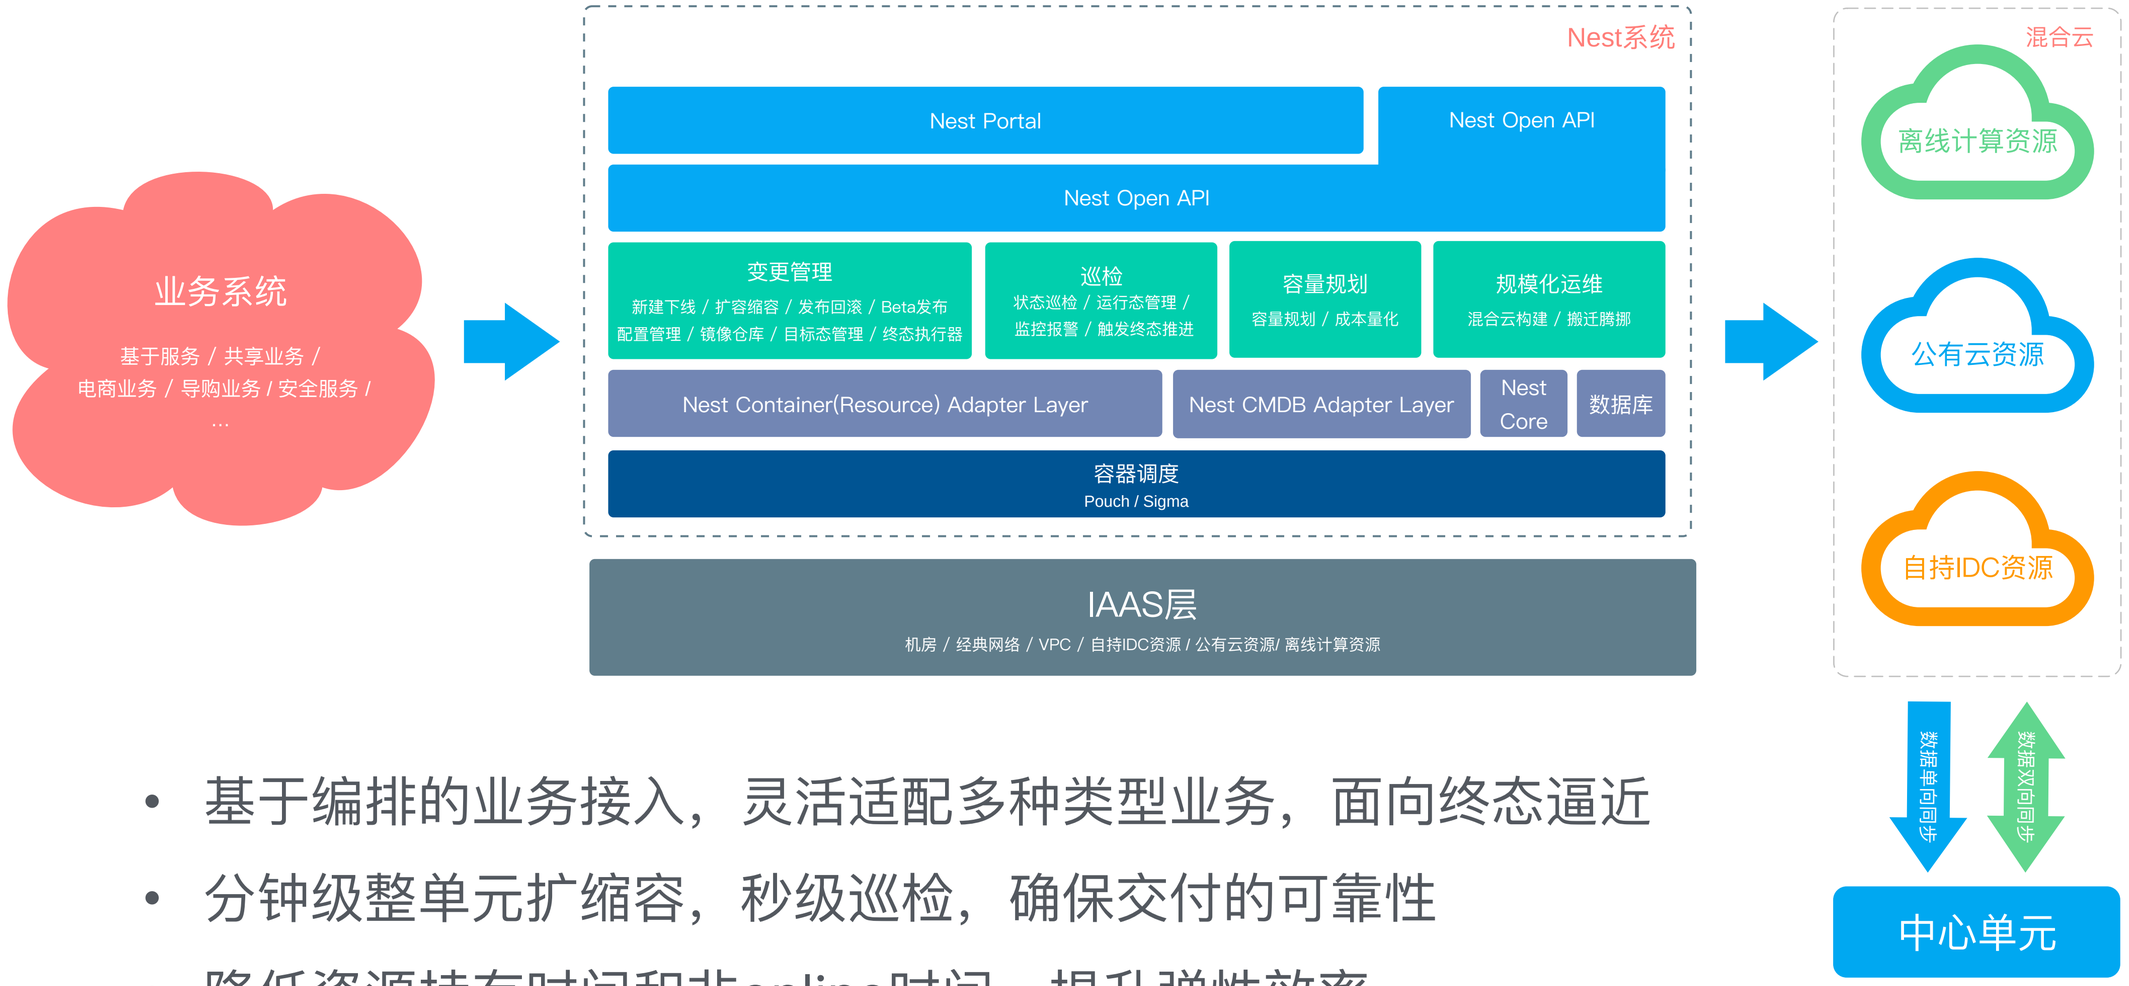

- 基于编排的业务接入，灵活适配多种类型业务，面向终态逼近
- 分钟级整单元扩缩容，秒级巡检，确保交付的可靠性
- 降低资源持有时间和非online时间，提升弹性效率
- 双11全面使用阿里云弹性基础设施，8小时快速构建全球最大混合云

双11云化架构运维体系

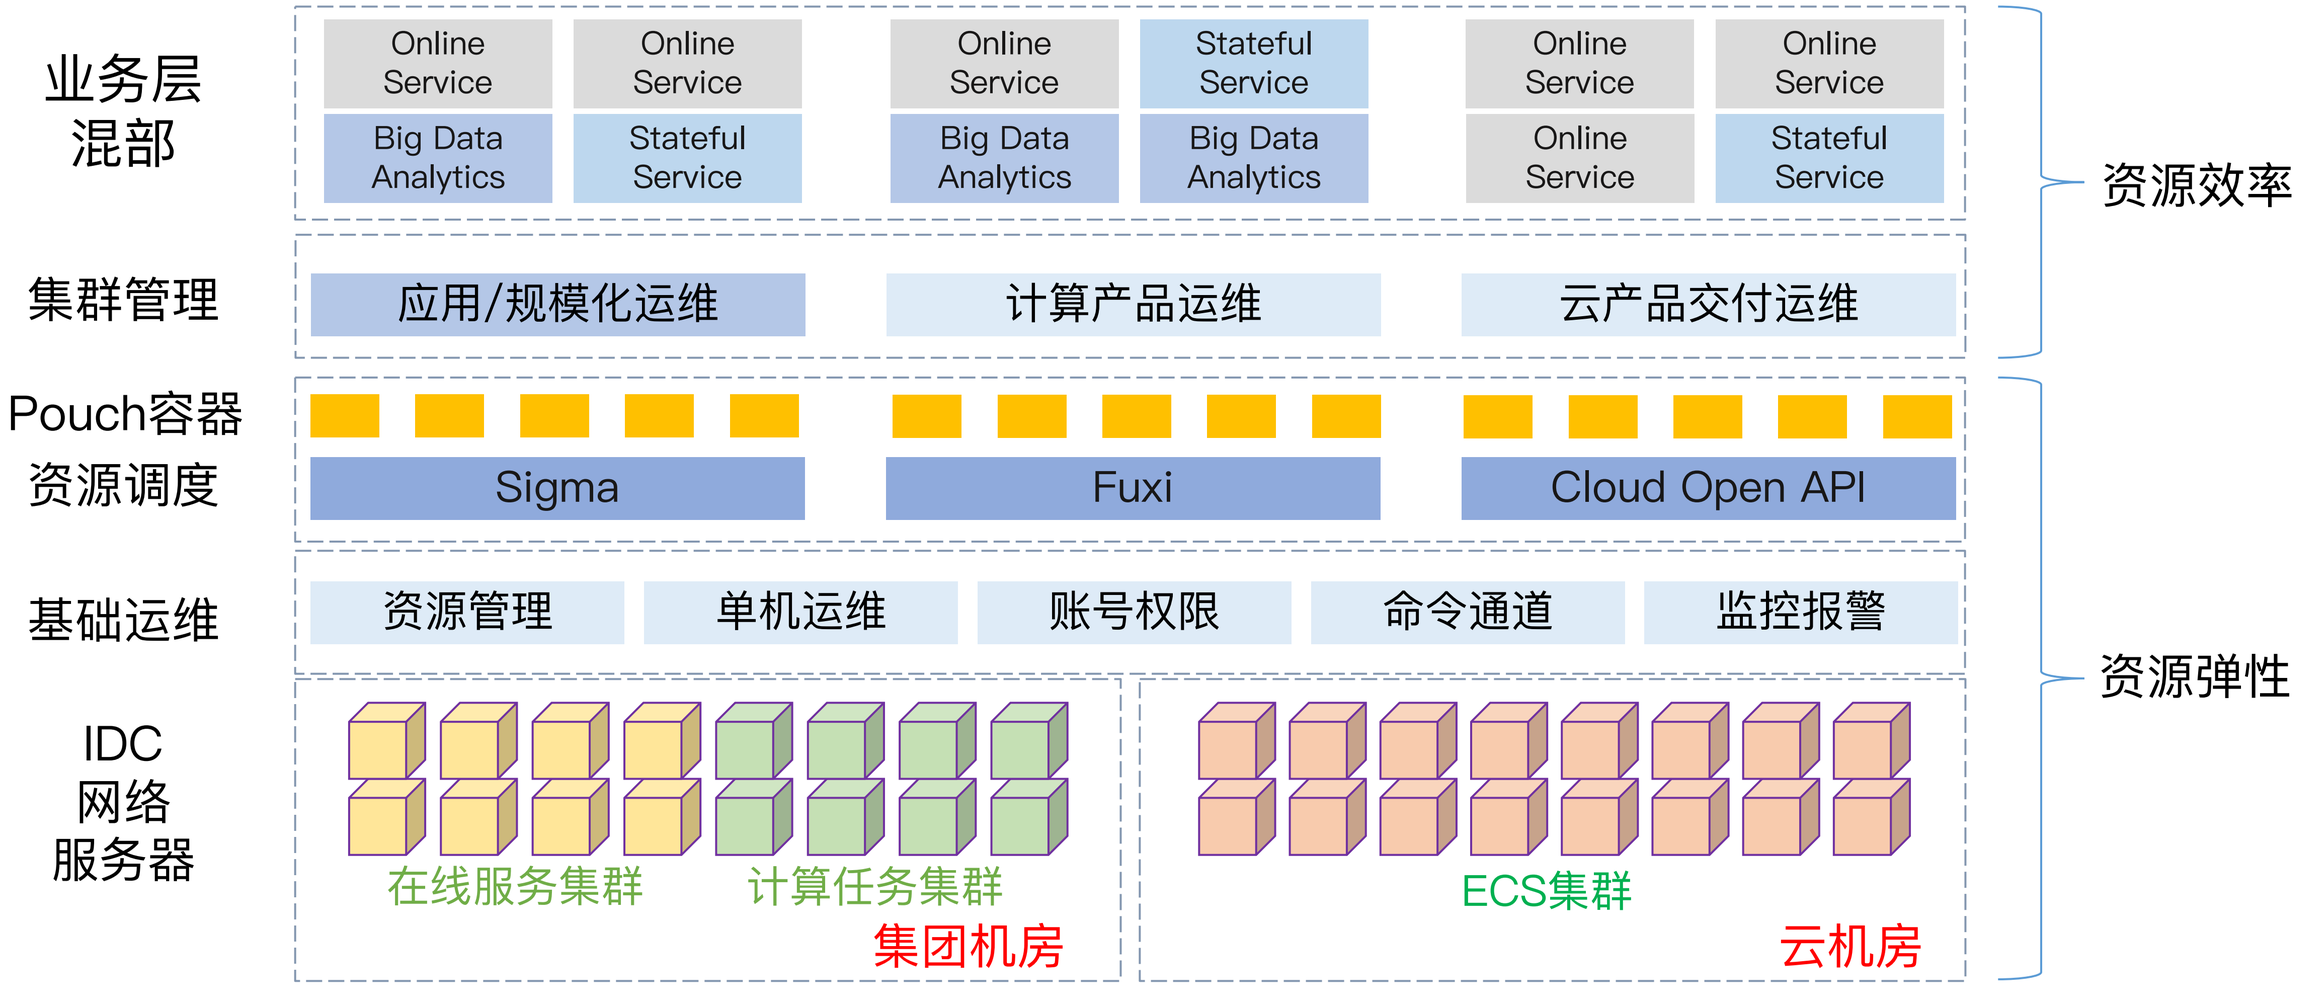

- datacenter as a computer，多个数据中心像一台计算机一样来管理，可以跨多个不同的平台来调度业务发展所需的资源
- 构建混合云以极低成本拿到服务器，解决有没有的问题，通过分时复用和混部大幅提升资源利用率，解决好不好的问题
- 真正实现弹性资源平滑复用、任务灵活混合部署，用最少服务器，最短时间最优效率完成容量目标
- 通过云化架构使双11新增IT成本下降50%，使日常IT成本下降30%， 带来集群管理和调度领域的技术价值爆发

Sigma敏捷版

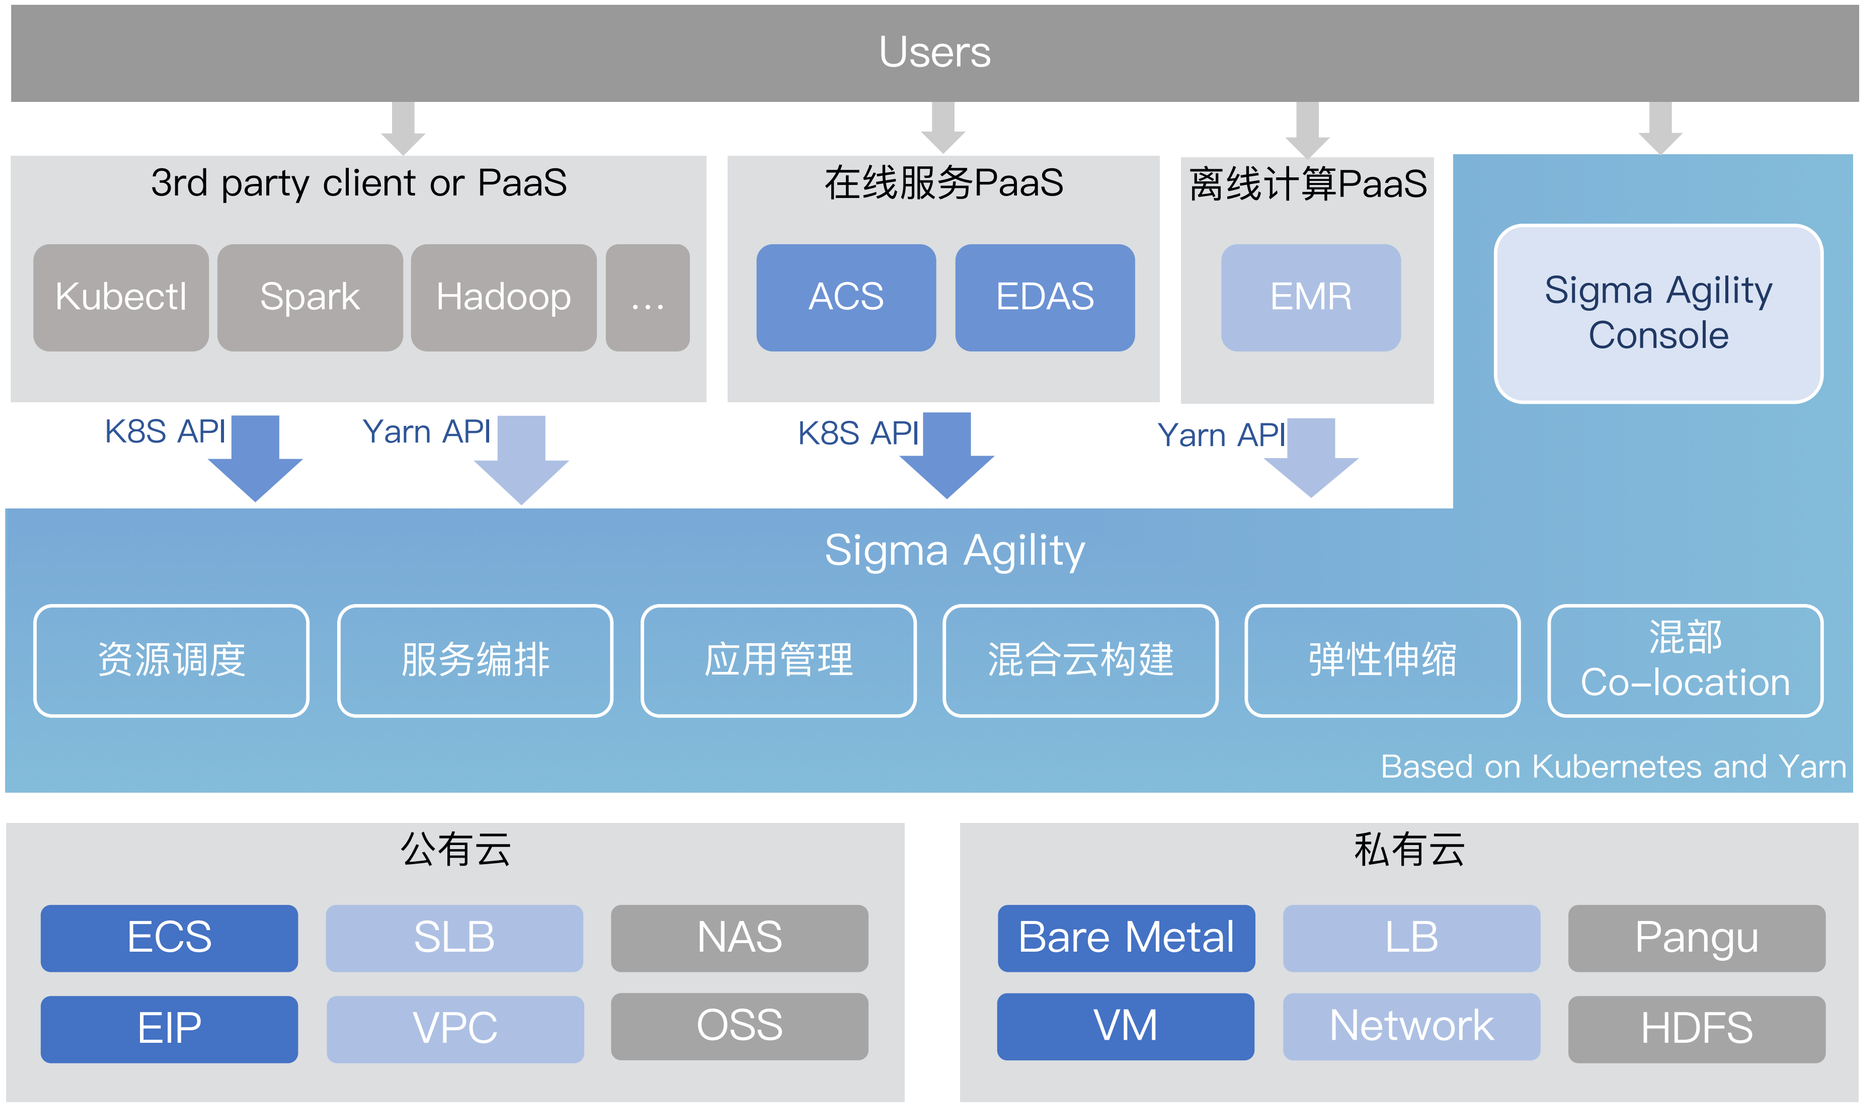

定位

- 阿里内部调度、容器、运维领域优势技术输出
- 兼容Kubernetes架构和标准
- 提供企业级容器应用管理能力，提高企业IT效率

优势

- 混部（Co-location）
- 灵活的调度策略和算法
- 快速自动化混合云构建
- 经过双11规模化检验

云化架构及双11未来的思考

- 提升IDC资源利用率，扩大调度规模和混部形态，继续释放规模效益下的技术红利
- 面向终态的体系编排结构，资源持有时间优化30%，持续降低大促交易成本
- 技术变量的采集、分析、预测，微观视角剖析，数据算法驱动智能决策处理
- 通过数据化、智能化，人与机器智能协同指挥，提升双11准备和作战效率
- 加速基础技术迭代，体验、效率、成本和最大吞吐能力找到新的平衡点

ATA
互通 合作 成长

云栖社区
CODING LIFE

Thanks